

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

федеральное государственное бюджетное образовательное учреждение высшего
образования

«Новгородский государственный университет имени Ярослава Мудрого»

НАУЧНО-ИССЛЕДОВАТЕЛЬСКАЯ РАБОТА

**«Методика адаптации моделей компьютерного зрения для контроля качества литых
изделий на edge-устройствах с различными ресурсными ограничениями»**

Выполнил магистрант:
Филиппов Иван Иванович

Научный руководитель, доцент:
Телина Ирина Сергеевна

2026, Великий Новгород

Содержание

Введение	2
1 Основная часть	3
1.1 Обзор задачи и существующих работ	3
1.2 Данные и аудит исходного split	4
1.3 Формирование deduplicated split	4
1.4 Методика адаптации моделей	5
1.5 Экспериментальный протокол	5
1.6 Результаты на deduplicated split	5
1.7 Exact TFLite/INT8-конвертация	7
1.8 Confidence-based triage	8
1.9 Сравнение с исходным split и опубликованными ориентирами	9
1.10 Практическая значимость и ограничения	10
Заключение	10
Список использованных источников	11
Приложения	13
Приложение А. Схема воспроизводимого пайплайна	13
Приложение Б. Основные артефакты эксперимента	13
Приложение В. Примеры изображений датасета	14
Приложение Г. Диагностические графики	14
Приложение Д. Ограничения интерпретации	14

Введение

Визуальный контроль качества является одной из ключевых задач промышленной автоматизации. Для литых изделий характерны дефекты поверхности, формы или структуры, которые могут быть выявлены по изображению детали. Ошибка контроля может приводить к двум типам последствий: пропуск дефектной детали и ошибочная отправка годной детали на дополнительную проверку. В промышленной постановке первый тип ошибки обычно более критичен, поскольку дефектное изделие может попасть на следующий этап производства или к конечному потребителю.

Современные модели компьютерного зрения позволяют достигать высокого качества в задачах классификации изображений. Однако прямая переносимость таких моделей на производственные edge-устройства ограничена аппаратными ресурсами. Одни сценарии допускают использование персонального компьютера, другие требуют работы на одноплатном компьютере уровня Raspberry Pi, а наиболее жесткие сценарии предполагают микроконтроллерный режим уровня OpenMV. Эти профили различаются по доступной памяти, вычислительной мощности, допустимой задержке и поддерживаемым форматам моделей.

Проблематика исследования состоит в необходимости не просто обучить точную модель классификации дефектов, а построить воспроизводимую методику адаптации модели к разным ресурсным профилям. Такая методика должна учитывать качество классификации, размер модели, задержку инференса, формат TFLite/INT8 и возможность отправки неуверенных случаев на ручную проверку.

Объектом исследования являются модели компьютерного зрения для промышленного визуального контроля качества. Предметом исследования является методика адаптации моделей компьютерного зрения к edge-устройствам с различными ресурсными ограничениями.

Гипотеза исследования заключается в том, что легковесная модель после адаптации и exact TFLite INT8-конвертации может сохранить приемлемое качество выявления дефектов на более строгом deduplicated split при радикальном уменьшении размера модели.

Актуальность работы определяется потребностью промышленности в переносимых и экономичных системах визуального контроля. На практике важно не только получить высокую ассигуру на тестовой выборке, но и понимать, насколько модель пригодна для исполнения на ограниченном устройстве, каков риск пропуска дефектов и как меняется качество после квантизации.

Научная новизна состоит в resource-aware методике адаптации: используется deduplicated-валидация, сравниваются PC/SBC/micro-edge профили, выполняется exact TFLite INT8-конвертация micro-edge модели и совместно анализируются качество, размер, latency и confidence-based triage. При этом не утверждается, что задача классификации дефектов литья решена впервые; вклад работы состоит в строгом и воспроизводимом сравнении качества и ресурсной стоимости.

Цель работы: разработать и экспериментально проверить методику адаптации моделей компьютерного зрения для контроля качества литых изделий на edge-устройствах раз-

ных ресурсных классов.

Для достижения цели поставлены задачи: изучить постановку задачи визуального контроля литых изделий; подготовить воспроизводимый пайплайн работы с датасетом; выполнить аудит исходного split на наличие дубликатов; сформировать deduplicated split; обучить и оценить модели трех профилей; выполнить exact TFLite/INT8-конвертацию micro-edge модели; провести анализ confidence-based triage; сравнить результаты с исходным split и опубликованными ориентирами; сформулировать ограничения и направления дальнейшей работы.

Методы исследования включают сверточные нейронные сети, transfer learning, легковесные архитектуры, квантизацию INT8, анализ метрик бинарной классификации, hash/perceptual-hash аудит данных, измерение latency и сравнительный анализ качества и ресурсоемкости.

Работа состоит из введения, основной части, заключения, списка источников и приложений. В основной части рассматриваются существующие подходы, данные и аудит split, методика адаптации, экспериментальный протокол, результаты на deduplicated split, exact TFLite/INT8-конвертация и ограничения исследования.

1. Основная часть

1.1. Обзор задачи и существующих работ

Датасет *Casting Product Image Data for Quality Inspection* используется в работах по визуальному контролю качества литых изделий [3]. Обычно задача формулируется как бинарная классификация изображений на годные и дефектные изделия. В опубликованных работах применяются классические CNN, transfer learning, MobileNetV2, MobileNetV3, Xception, DenseNet-подобные и гибридные архитектуры [11, 5].

Для этого датасета в литературе встречаются высокие показатели accuracy, в том числе выше 99%. Например, опубликованы работы по AI-based quality inspection, Xception с аугментацией, HiDraNet и ensemble/XAI-подходам [8, 6, 1, 12]. Однако прямое сравнение таких результатов затруднено: отличаются split, preprocessing, число эпох, аугментации и методика проверки дубликатов. Поэтому опубликованные результаты используются в данной работе как ориентиры, а не как строго сопоставимый leaderboard.

В контексте edge AI важны не только показатели качества, но и размер модели, поддержка, формат исполнения и поддержка целевого устройства. Для микроконтроллеров и маломощных edge-устройств применяются TensorFlow Lite Micro, LiteRT for Microcontrollers, MCUNet-подходы и специализированные benchmark-наборы вроде MLPerf Tiny [13, 4, 7, 2]. Документация OpenMV показывает, что перенос модели на камеру микроконтроллерного класса требует отдельной проверки формата, операций и памяти [10, 9].

Отличие настоящей работы состоит в том, что классификация дефектов рассматривается совместно с ресурсными ограничениями. Модель оценивается не только по accuracy, F1 и defective recall, но также по размеру, latency, FPS, возможности TFLite/INT8-конвертации

и режиму ACCEPT/REVIEW.

1.2. Данные и аудит исходного split

В работе используется датасет *Casting Product Image Data for Quality Inspection*. Содержательно датасет включает изображения литых изделий двух классов: годные изделия и дефектные изделия. В экспериментальном пайплайне классы приведены к стабильному отображению:

Класс	Метка
ok	0
defective	1

При первичной оценке на исходном split были получены высокие метрики, однако перед финальной интерпретацией был выполнен аудит данных на наличие утечки. Проверялись exact duplicates по SHA1-хэшу и near-duplicates по average perceptual hash. Аудит показал наличие 64 cross-split exact duplicate groups и 191085 near cross-split pairs при пороге average hash distance ≤ 4 .

Наличие таких совпадений означает, что модель могла видеть в обучении изображения, совпадающие или почти совпадающие с тестовыми. Следовательно, метрики на исходном split могут быть завышены. Поэтому в данной работе исходный split используется только как дополнительное сравнение, а основным строгим результатом является deduplicated split.

1.3. Формирование deduplicated split

Deduplicated split формировался по группам изображений. В одну группу объединялись изображения с одинаковым SHA1-хэшем и визуально близкие изображения по perceptual hash. После этого вся группа назначалась только в один split: train, validation или test. Такой подход предотвращает попадание одинаковых или почти одинаковых изображений одновременно в обучение и тестирование.

При формировании clean split сохранялся баланс классов насколько это возможно при групповом разбиении. Содержимое датасета не изменялось, а clean split был материализован отдельно от исходного разбиения. Итоговая структура приведена в таблице 1.

Таблица 1: Состав deduplicated split

Split	OK	Defective	Total
Train	2325	3022	5347
Validation	501	728	1229
Test	311	461	772

Такое разбиение является более строгим, чем исходный split, поскольку снижает риск завышения качества за счет дубликатов. При этом average hash является эвристикой, поэтому

результаты аудита следует трактовать как практическую проверку, а не как математически исчерпывающее доказательство отсутствия всех похожих изображений.

1.4. Методика адаптации моделей

Предложенная методика включает несколько этапов. На первом этапе обучается PC baseline-модель, задающая верхнюю планку качества. На втором этапе используется более компактная модель для Raspberry Pi-like профиля. На третьем этапе строится micro-edge модель с минимальным размером и высокой скоростью инференса. На четвертом этапе micro-edge модель конвертируется в TFLite FP32 и INT8. На пятом этапе анализируется confidence-based triage.

Профили эксперимента приведены в таблице 2.

Таблица 2: Профили адаптации

Профиль	Назначение	Основной критерий
baseline_pc_dedup	PC baseline	верхняя планка качества
edge_sbc_dedup	Raspberry Pi-like	баланс качества и latency
micro_edge_dedup	OpenMV-like	минимальный размер и INT8

Для промышленного контроля особое значение имеет defective recall и число false OK. Пропуск дефектного изделия хуже, чем отправка годного изделия на дополнительную проверку. Поэтому качество модели оценивалось не только общей ассурасу, но и recall по классу defective.

1.5. Экспериментальный протокол

Все основные результаты получены на deduplicated split. Для каждого профиля сохранялись веса лучшей модели, metrics.json, classification report, confusion matrix и predictions. Для latency использовался batch size 1. Значения latency являются проху-измерениями на текущей вычислительной среде и не являются аппаратными замерами на Raspberry Pi или OpenMV.

Для micro-edge модели была выполнена exact TFLite/INT8-конвертация. Под exact-конвертацией понимается перенос весов обученной PyTorch-модели в эквивалентную Keras-модель без дополнительного обучения, проверка эквивалентности предсказаний и последующий экспорт в TFLite. Это важно, поскольку отдельное обучение Keras-модели не является проверкой той же самой обученной edge-модели.

1.6. Результаты на deduplicated split

Основные результаты на clean test представлены в таблице 3. Главный вывод состоит в том, что micro-edge модель сохраняет качество на строгом split при радикальном уменьшении размера.

Таблица 3: Качество и ресурсные характеристики на deduplicated split

Модель	Acc.	F1	Def. recall	False OK	False defective	Размер, KB	Latency, ms
baseline_pc_dedup	0.9689	0.9741	0.9783	10	14	8919.5	4.451
edge_sbc_dedup	0.9702	0.9745	0.9544	21	2	6057.6	4.267
micro_edge_dedup	0.9767	0.9804	0.9783	10	8	101.3	0.479
micro INT8 exact	0.9754	0.9795	0.9848	7	12	31.0	0.441

Результат `micro_edge_dedup` показывает ассурасу 0.9767 и F1 0.9804 при размере 101.3 KB. Exact INT8-версия уменьшает размер до 31.0 KB и сохраняет ассурасу 0.9754, F1 0.9795 и defective recall 0.9848. Число false OK для INT8-модели равно 7 на clean test.

Таким образом, на более строгом split edge-методика сохраняет работоспособность. Более крупные модели не дают решающего преимущества в качестве, тогда как micro-edge модель существенно выигрывает по размеру и latency. Это подтверждает гипотезу о возможности сохранить приемлемое качество при значительном уменьшении ресурсной стоимости.

Сравнение качества моделей на deduplicated split




Рис. 1: Сравнение качества моделей на deduplicated split

Сравнение размера моделей




Рис. 2: Сравнение размеров моделей в KB, логарифмическая шкала

Рисунки 1 и 2 показывают, что micro-edge и INT8-вариант сохраняют близкое качество при резком уменьшении размера модели. Это является основным ресурсным выигрышем предложенной методики.

1.7. Exact TFLite/INT8-конвертация

Для micro-edge модели были получены два TFLite-файла:

- `micro_edge_dedup_exact_fp32.tflite`: 97.0 KB;
- `micro_edge_dedup_exact_int8.tflite`: 31.0 KB.

TFLite INT8-модель использует входной тензор формы [1, 128, 128, 3] типа int8 и выходной тензор [1, 2] типа int8. В списке операций зафиксированы CONV_2D, MAX_POOL_2D, MEAN, FULLY_CONNECTED и DELEGATE. Набор операций выглядит простым для дальнейшей проверки в TFLite Micro/OpenMV-like режиме, однако фактическая совместимость требует проверки на целевом firmware.

Важно подчеркнуть, что модель не запускалась на OpenMV или Raspberry Pi. Полученный TFLite INT8-файл является корректным артефактом для следующего этапа проверки, но не является доказательством аппаратного внедрения.




Рис. 3: Pareto-анализ: F1 и размер модели




Рис. 4: Сравнение latency, прокси-измерение

Pareto-анализ показывает, что INT8 micro-edge модель не является «лучшей вообще» по всем возможным критериям, но является наиболее ресурсно-эффективной в данном эксперименте: качество остается близким к PyTorch-модели, а размер и latency минимальны среди рассмотренных вариантов.

1.8. Confidence-based triage

Для промышленного контроля полезно не только классифицировать каждое изображение, но и отправлять сомнительные случаи на REVIEW. В confidence-based triage автома-

тическое решение принимается только при confidence выше заданного threshold. При меньшей уверенности изделие направляется на ручную проверку.

Для TFLite INT8-модели нулевой unsafe-error threshold найден не был. Лучший low-risk режим имел threshold 0.95, review rate 0.1723, accepted accuracy 0.9984 и 1 unsafe error. Это означает, что примерно 82.8% изображений принимаются автоматически, а 17.2% направляются на REVIEW. Такой режим может быть полезен, когда требуется снизить риск пропуска дефектов при сохранении высокой доли автоматической обработки.

Таблица 4: Low-risk confidence triage для TFLite INT8

Threshold	Coverage	Review rate	Accepted acc.	Accepted def. recall	Unsafe errors
0.95	0.8277	0.1723	0.9984	0.9977	1

АССЕПТ/РЕВЬЮ: снижение риска автоматического решения




Рис. 5: Компромисс confidence-based triage для INT8 micro-edge модели

1.9. Сравнение с исходным split и опубликованными ориентирами

После перехода от исходного split к deduplicated split метрики снизились. Для baseline accuracy уменьшилась на 0.0241, F1 на 0.0204. Для edge_sbc accuracy уменьшилась на 0.0200, F1 на 0.0178. Для micro_edge accuracy уменьшилась на 0.0163, F1 на 0.0141.

Таблица 5: Изменение качества после перехода к deduplicated split

Профиль	Δ accuracy	Δ F1
baseline	-0.0241	-0.0204
edge_sbc	-0.0200	-0.0178
micro_edge	-0.0163	-0.0141

Это снижение подтверждает, что исходный split мог завышать качество. Однако падение не является критическим: все модели сохраняют F1 выше 0.97. Поэтому deduplicated split дает более честную оценку, не отменяя применимости предложенной методики.

Опубликованные работы по этому датасету иногда сообщают ассурасу выше 99%, однако такие значения получены при иных условиях split, preprocessing и обучения. Поэтому в данной НИР они рассматриваются как ориентиры. Наиболее важным результатом настоящей работы является не абсолютное превосходство над SOTA, а демонстрация ресурсно-ориентированной адаптации с проверкой данных, TFLite/INT8 и triage.

1.10. Практическая значимость и ограничения

Практическая значимость работы состоит в подготовке воспроизводимого пайплайна для оценки моделей визуального контроля качества в условиях ресурсных ограничений. Такой подход может применяться при проектировании систем поддержки промышленного контроля, в том числе в решениях уровня Ретинар, где требуется учитывать не только качество модели, но и ограничения устройства и риск неуверенных решений.

Ограничения исследования следующие. Во-первых, latency является проху на текущей машине, а не аппаратным замером на Raspberry Pi или OpenMV. Во-вторых, модели не запускались на реальных целевых устройствах. В-третьих, совместимость TFLite Micro/OpenMV firmware требует отдельной проверки. В-четвертых, average hash для near-duplicates является эвристикой. В-пятых, сравнение с опубликованными работами условное из-за различий split, preprocessing и epochs. В-шестых, датасет содержит однотипные изображения, поэтому перенос на другое производство требует валидации или дообучения.

Заключение

В работе разработана и экспериментально проверена методика адаптации моделей компьютерного зрения для контроля качества литых изделий на edge-устройствах разных ресурсных классов. Цель достигнута на уровне воспроизводимой исследовательской методики и экспериментальной проверки на deduplicated split.

Выполнен аудит исходного split и обнаружены cross-split duplicates и near-duplicates. Поэтому основным строгим результатом выбран deduplicated split, сформированный по группам похожих изображений. На нем micro-edge модель достигла accuracy 0.9767 и F1 0.9804 при размере 101.3 KB. Exact TFLite INT8-версия достигла accuracy 0.9754, F1 0.9795 и defective recall 0.9848 при размере 31.0 KB.

Полученные результаты подтверждают гипотезу: легковесная модель после адаптации и exact TFLite INT8-конвертации может сохранить приемлемое качество выявления дефектов при значительном снижении ресурсной стоимости. При этом работа не утверждает создание готовой промышленной системы. Для внедрения необходимы аппаратные измерения на целевых устройствах, проверка firmware-совместимости, multi-seed validation и тестирование на данных конкретной производственной линии.

Список литературы

- [1] Advances in Mechanical Engineering. Identifying defective casting products using hierarchical defect recognition architecture. 2025. Published orientation point for casting product dataset.
- [2] Colby Banbury, Vijay Janapa Reddi, Peter Lam, William Fu, Amin Fazel, Jeremy Holleman, Xinyuan Huang, Robert Hurtado, David Kanter, Anton Lokhmotov, et al. Mlperf tiny benchmark. In *Proceedings of Machine Learning and Systems*, 2021.
- [3] Ravirajsinh Dabhi. Casting product image data for quality inspection. <https://www.kaggle.com/datasets/ravirajsinh45/real-life-industrial-dataset-of-casting-product>, 2020. Kaggle dataset.
- [4] Google AI Edge. Litert for microcontrollers. <https://ai.google.dev/edge/litert/microcontrollers>, 2026. Documentation.
- [5] Andrew Howard, Mark Sandler, Grace Chu, Liang-Chieh Chen, Bo Chen, Mingxing Tan, Weijun Wang, Yukun Zhu, Ruoming Pang, Vijay Vasudevan, Quoc V. Le, and Hartwig Adam. Searching for mobilenetv3. *Proceedings of the IEEE International Conference on Computer Vision*, 2019.
- [6] Journal of Theory and Practice of Engineering Science. Casting product image data for quality inspection with xception and data augmentation. 2023. Exact comparability depends on split and preprocessing.
- [7] Ji Lin, Wei-Ming Chen, Yujun Lin, Chuang Gan, and Song Han. Mccnet: Tiny deep learning on iot devices. *Advances in Neural Information Processing Systems*, 2020.
- [8] Micromachines. Artificial intelligence-based smart quality inspection for manufacturing. *Micromachines*, 2023. Reported metrics are not directly comparable due to protocol differences.
- [9] OpenMV. Openmv cam h7 plus. <https://openmv.io/products/openmv-cam-h7-plus>, 2026. Product documentation.
- [10] OpenMV. Openmv documentation. <https://docs.openmv.io/>, 2026. Documentation.
- [11] Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov, and Liang-Chieh Chen. Mobilenetv2: Inverted residuals and linear bottlenecks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018.
- [12] Tech Science Press. Bearfusionnet for casting product defect classification. 2026. Reported accuracy/F1 are conditional on authors' protocol.

- [13] TensorFlow. Tensorflow lite for microcontrollers. <https://www.tensorflow.org/lite/microcontrollers>, 2026. Documentation.

Приложения

Приложение А. Схема воспроизводимого пайплайна

Пайплайн исследования включает следующие этапы: загрузка фиксированного датасета; валидация структуры классов; аудит дубликатов; формирование deduplicated split; обучение трех профилей моделей; оценка качества; benchmark latency и размера; exact TFLite/INT8-конвертация; confidence-based triage; сравнение original split и deduplicated split; формирование итоговых таблиц.

Приложение Б. Основные артефакты эксперимента


Артефакт	Расположение внутри проекта			
Clean split	каталог <code>processed_clean</code> в <code>dedup-training</code> эксперименте			
Beca baseline	файл	<code>best.pt</code>	для	профиля
		<code>baseline_pc_dedup</code>		
Beca edge_sbc	файл	<code>best.pt</code>	для	профиля
		<code>edge_sbc_dedup</code>		
Beca micro_edge	файл	<code>best.pt</code>	для	профиля
		<code>micro_edge_dedup</code>		
TFLite FP32	FP32-экспорт micro-edge модели			
TFLite INT8	INT8-экспорт micro-edge модели			

Код, конфигурации, таблицы результатов, exact TFLite INT8-модель и инструкции воспроизведения выделены в отдельный reference snapshot. Датасет Kaggle не включается в репозиторий и скачивается отдельно. Репозиторий доступен по ссылке: <https://github.com/vanekus-ukus/edge-casting-quality-inspection>. Основные артефакты: clean split manifest, metrics, tables, exact TFLite FP32/INT8, LaTeX/PDF НИР.

Приложение В. Примеры изображений датасета



Класс ok



Класс defective

Рис. 6: Примеры изображений из clean test split

Приложение Г. Диагностические графики

Confusion matrix: micro-edge INT8 exact

	Pred: ok	Pred: defective
True: ok	299	12
True: defective	7	454

false OK = 7; false defective = 12

Рис. 7: Confusion matrix для exact TFLite INT8 модели на clean test

Приложение Д. Ограничения интерпретации

Исходный split датасета содержит дубликаты и near-duplicates, поэтому результаты на нем следует использовать только как дополнительное сравнение. Основными результатами являются значения на deduplicated split. Latency является проху-измерением на текущей машине. Raspberry Pi и OpenMV аппаратно не тестировались. TFLite INT8-файл требует дальнейшей проверки на целевом firmware. Обобщение на другие производства требует отдельной валидации.